

Classificação de Manganês e Cobre na Folha da Mexerica, Orientado por Redes Neurais

Classification of Manganese and Copper in Tangerine Leaves, Guided by Neural Networks

Fagundes. L { lucas.fagundes3@fatec.sp.gov.br }
Freitas. A { amanda.freitas14@fatec.sp.gov.br }
Freitas. V { valeria.freitas@fatec.sp.gov.br }

RESUMO

Este artigo tem como objetivo alinhar-se ao Objetivo de Desenvolvimento Sustentável (ODS) 2 — Fome Zero e Agricultura Sustentável da Agenda 2030 da ONU, visando reduzir perdas na produção agrícola e promover práticas agrícolas mais sustentáveis. A proposta apresentada busca auxiliar agricultores na identificação rápida e precisa de deficiências nutricionais em plantas, utilizando visão computacional para analisar imagens de folhas capturadas por drones ou enviadas pelos produtores. O trabalho descreve o desenvolvimento inicial do projeto NitrusLeaf, um aplicativo para celular e site, que emprega técnicas de Inteligência Artificial (IA) para identificar deficiências nutricionais de cobre e manganês em folhas de *Citrus reticulata* (mexerica). O treinamento da IA será realizado com redes neurais convolucionais (CNNs), utilizando um banco de dados composto por imagens de folhas com e sem deficiências. Espera-se que, ao final da pesquisa, o NitrusLeaf se consolide como uma ferramenta eficaz para apoiar a agricultura sustentável.

PALAVRAS-CHAVE: *Citrus reticulata*; Deficiência nutricional; Visão computacional; Manganês; Cobre.

ABSTRACT

This article aims to align with the Sustainable Development Goal (SDG) 2 — Zero Hunger and Sustainable Agriculture of the UN 2030 Agenda, aiming to reduce losses in agricultural production and promote more sustainable agricultural practices. The proposed application seeks to assist farmers in the rapid and accurate identification of nutritional deficiencies in plants, using computer vision to analyze images of leaves captured by drones or submitted by producers. This work presents the initial development of the NitrusLeaf project, a mobile app and website that utilizes Artificial Intelligence (AI) techniques to identify nutritional deficiencies of copper and manganese in *Citrus reticulata* (mandarin) leaves. The AI will be trained using convolutional neural networks (CNNs), employing a database of images of leaves with and without deficiencies. It is expected that, by the end of the research, NitrusLeaf will be consolidated as an effective tool to support sustainable agriculture.

KEYWORDS: *Citrus reticulata*; Nutritional deficiency; Computer Vision; Manganese; Copper.

INTRODUÇÃO

A escassez de alimentos ainda é um desafio global, agravado por fatores como pobreza, conflitos e mudanças climáticas. Como resposta, a Organização das Nações Unidas (ONU) estabeleceu, em 2015, os Objetivos de Desenvolvimento Sustentável (ODS), entre eles o ODS 2 — Fome Zero e Agricultura Sustentável, que busca garantir segurança alimentar por meio do aumento da produtividade agrícola e do uso de tecnologias sustentáveis (Fundecitrus, 2018).

No Brasil, um dos entraves à produtividade agrícola é a deficiência nutricional nas plantas, especialmente em culturas como a *Citrus reticulata* (mexerica), bastante suscetível a desequilíbrios minerais. Tais deficiências podem afetar diretamente o crescimento e o rendimento da produção, prejudicando pequenos e médios agricultores (Bueno; Gasparotto, 1999).

Entre os problemas fitossanitários que atingem os citros, destaca-se o greening (HLB), uma doença sem cura que compromete severamente a produção. Embora o foco deste projeto não seja essa doença, é importante mencionar que seus sintomas visuais, como clorose e deformações nas

folhas, podem ser confundidos com deficiências nutricionais, como as de manganês e cobre — foco deste estudo. Isso torna o diagnóstico preciso ainda mais relevante (Fundecitrus, 2018; Aregbe; Farnsworth; Simnitt, 2024).

A deficiência de manganês causa clorose internerval nas folhas jovens, enquanto a de cobre pode levar ao encurtamento dos ramos, folhas pequenas e gomose nos frutos. Ambas influenciam diretamente a produtividade e estão associadas ao pH do solo — sendo a carência de manganês mais comum em solos ácidos e a de cobre em solos mais alcalinos (Bruna, 2019; Machado, 2022).

Considerando esse cenário, este projeto propõe o desenvolvimento de um sistema baseado em Inteligência Artificial (IA) para auxiliar produtores rurais na identificação rápida e precisa dessas deficiências em folhas de mexerica. Por meio da análise de imagens capturadas via smartphones, o sistema utilizará visão computacional, com suporte de redes neurais convolucionais (CNNs) e técnicas de aprendizado profundo (Deep Learning), para classificar a saúde foliar de forma prática, acessível e em tempo real (Qin et al., 2018).

Ao integrar essas tecnologias ao contexto da agricultura nacional, o projeto visa contribuir diretamente com os objetivos do ODS 2, promovendo práticas agrícolas mais sustentáveis, reduzindo perdas na produção e fortalecendo a segurança alimentar por meio da inovação tecnológica (Christin; Hervet; Lecomte, 2019).

OBJETIVO

A agricultura de citros enfrenta diversos tipos de doenças e deficiências nutricionais que comprometem o desenvolvimento saudável das plantas. Essas condições podem ser identificadas visualmente por alterações nas folhas, cascas e frutos, porém o diagnóstico tradicional por meio de análises químicas é demorado, exige coleta física e depende de infraestrutura especializada. A utilização de inteligência artificial (IA) para detectar padrões visuais oferece uma alternativa acessível e eficaz, permitindo diagnósticos em tempo real diretamente no campo.

O projeto tem como objetivo principal desenvolver um sistema inteligente baseado em visão computacional para identificar deficiências de manganês e cobre em folhas de *Citrus reticulata* (mexerica), por meio da análise de imagens capturadas com dispositivos móveis. O sistema visa proporcionar agilidade, precisão e autonomia ao agricultor, contribuindo para a sustentabilidade da produção e a redução de perdas.

Os objetivos principais do projeto são:

1. Aprofundar na coleta e organização de informações sobre os sintomas visuais das deficiências nutricionais específicas da mexerica, com foco em cobre e manganês.
2. Desenvolver um banco de dados com imagens rotuladas de folhas apresentando diferentes níveis de deficiência, com expectativa de compor uma base robusta e representativa.
3. Realizar o treinamento da IA utilizando uma arquitetura de rede neural convolucional (CNN), aplicando técnicas de aumento de dados (data augmentation), validação cruzada e ajuste de hiperparâmetros.
4. Implementar uma solução funcional que possibilite ao agricultor, ao apontar a câmera do celular para a folha, receber um diagnóstico automatizado com base em IA e visão computacional.
5. Avaliar a precisão do sistema desenvolvido, comparando-o com métodos tradicionais de análise foliar e de solo, para verificar sua eficácia no ambiente agrícola real.

Além disso, o projeto também contempla os seguintes objetivos específicos:

1. Habilitar o registro dos diagnósticos no sistema, permitindo ao usuário cadastrar o número da planta e o talhão, facilitando o acompanhamento e controle nutricional.

2. Implementar uma funcionalidade de histórico, permitindo ao agricultor visualizar a evolução do estado das plantas e compará-lo com registros anteriores.
3. Criar um módulo de recomendações técnicas, com sugestões agronômicas baseadas nos resultados obtidos, visando a aplicação mais assertiva de insumos.
4. Prever, para fases futuras, o uso de drones para captura de imagens aéreas, com o objetivo de identificar áreas críticas da plantação.
5. Incluir, posteriormente, funcionalidades como mapas interativos e mapas de calor, que indiquem visualmente a distribuição das deficiências por talhão, facilitando a tomada de decisão.
6. Explorar a possibilidade de expansão da plataforma para outras culturas e deficiências nutricionais, visando aumentar o escopo e escalabilidade da solução.
7. Contribuir para a sustentabilidade agrícola por meio da redução de perdas por deficiência nutricional e aumento da rentabilidade dos produtores rurais por meio do uso direcionado de insumos.

ESTADO DA ARTE

Entre os muitos desafios enfrentados pelos agricultores, a deficiência de minerais nas plantas é uma preocupação significativa, pois pode resultar em perdas de produtividade e qualidade dos cultivos. A mexerica (*Citrus reticulata*) é uma das culturas suscetíveis a deficiências minerais, o que pode afetar seu crescimento, desenvolvimento e produção.

O artigo de **EstadoArte1** discute avanços recentes nas tecnologias de visão computacional, aprendizado de máquina (ML) e aprendizado profundo (DL), que têm sido aplicadas ao monitoramento agrícola para melhorar a produtividade e a qualidade das colheitas. Entre as tecnologias abordadas, destacam-se imagens de satélite, sensoriamento remoto, Internet das Coisas (IoT), dispositivos de sensor e Veículos Aéreos Não Tripulados (VANTs). Esses sistemas são utilizados para capturar dados visuais e detectar deficiências nutricionais em tempo real, permitindo um diagnóstico precoce e aumentando a eficiência na aplicação de insumos agrícolas.

O artigo cita trabalhos que demonstram como a visão computacional, combinada com ML e DL, pode identificar padrões visuais como coloração, textura e bordas em imagens de plantas. Esse exemplo ilustra como essas técnicas permitem um diagnóstico não invasivo, usando câmeras digitais e algoritmos avançados para diferenciar entre folhas saudáveis e folhas com deficiência nutricional.


Com base nesses avanços, é viável que o projeto NitrusLeaf implemente um sistema semelhante, utilizando smartphones e visão computacional para capturar e analisar imagens de folhas de mexerica. Com o suporte de algoritmos de ML/DL, o sistema pode processar essas imagens para identificar deficiências específicas, como de cobre e manganês, diretamente no campo.

O artigo de (**EstadoArte2**) explora um pipeline detalhado Figura 1 para identificar doenças e deficiências nutricionais em plantas, baseado em técnicas de processamento de imagem. Esse pipeline, ou sequência organizada de etapas, permite a análise automatizada e eficiente de imagens de plantas, produzindo diagnósticos agrícolas precisos. O pipeline descrito no artigo inclui as seguintes fases:

- **Aquisição de imagem:** envolve a captura de imagens de plantas utilizando câmeras, drones (Veículos Aéreos Não Tripulados - VANTs) ou dispositivos móveis. Essa etapa assegura que as imagens tenham qualidade suficiente para as fases subsequentes do processamento.
- **Pré-processamento:** técnicas de correção de ruído, ajuste de contraste e brilho, além de redimensionamento e rotação, são aplicadas para melhorar a qualidade da imagem e facilitar a segmentação.

- **Segmentação de imagem:** isola a folha ou parte relevante da planta, separando-a do fundo. Técnicas comuns incluem limiarização, segmentação por cor e abordagens de aprendizado de máquina.
- **Extração de características:** analisa e extrai informações importantes, como cor, textura e forma, essenciais para diferenciar entre folhas saudáveis e afetadas. Métodos como histogramas de cor e a Matriz de Co-ocorrência de Níveis de Cinza (GLCM) são comumente usados.
- **Classificação:** modelos de aprendizado de máquina ou redes neurais profundas (como CNNs e SVMs) são empregados para classificar as imagens, diferenciando folhas saudáveis das que apresentam deficiências ou doenças.
- **Deteção e Diagnóstico:** identifica a doença ou deficiência nutricional específica e gera recomendações com base nos resultados da classificação.

Figura 1 – Esquema do pipeline para detecção de doenças em plantas baseada em imagens



Fonte: Adaptado de (EstadoArte2)

Além disso, o artigo explora técnicas não intrusivas para a detecção de deficiências nutricionais, utilizando métodos avançados de análise de imagens. Por exemplo, uma tabela destaca o uso do sistema de cores RGB (Red, Green, Blue) para identificar deficiências de nutrientes, incluindo a deficiência de manganês em citrus. Essa abordagem reforça a viabilidade do projeto NitrusLeaf, que tem como objetivo identificar deficiências de cobre e manganês nas folhas de mexerica. Ao adotar essas tecnologias e adaptar o pipeline descrito, o NitrusLeaf poderá se consolidar como uma solução eficaz e prática para diagnósticos agrícolas baseados em visão computacional.

O artigo de **EstadoArte3** utiliza os modelos Inception-ResNet v2, Autoencoder de Rede Neural Convolutacional (CNN), e uma combinação desses dois modelos por meio de Ensemble Averaging para melhorar a detecção precoce de deficiências nutricionais de cálcio, nitrogênio e potássio em plantações de tomate. A identificação rápida dessas deficiências é essencial, pois a falta de intervenção pode levar a condições mais graves, incluindo doenças que afetam a produtividade e a saúde das plantas. Para garantir que os modelos fossem treinados com imagens robustas e representativas, os autores aplicaram técnicas de pré-processamento e aumento de dados (data augmentation), como ajuste de ângulo, brilho e contraste. Essas técnicas aumentaram a diversidade visual do conjunto de dados, ajudando os modelos a generalizar melhor e a detectar padrões de deficiência com mais precisão.

A escolha dos modelos Inception-ResNet v2 e Autoencoder foi motivada pela capacidade dessas arquiteturas em capturar características visuais complexas nas folhas e nos frutos, essenciais para distinguir entre deficiências nutricionais que compartilham sintomas visuais semelhantes. O Inception-ResNet v2, por exemplo, combina as vantagens das redes Inception e ResNet, permitindo

uma análise detalhada de padrões locais e globais na imagem. Já o Autoencoder oferece uma estrutura de compressão e reconstrução útil para destacar anomalias visuais, como as causadas por deficiências. O estudo usou um conjunto de 571 imagens de tomates cultivados em estufas, das quais 80% (461 imagens) foram destinadas ao treinamento e 20% (110 imagens) para a validação dos modelos. Após extensivos testes, os resultados mostraram que o Inception-ResNet v2 obteve uma precisão de 87,27%, o Autoencoder alcançou 79,09%, e a técnica de Ensemble Averaging conseguiu uma precisão de 91%.

As abordagens e metodologias deste artigo são relevantes para nosso projeto, pois ambos compartilham o foco em visão computacional e aprendizado profundo para a detecção de deficiências nutricionais em plantas. Enquanto o artigo de Tran et al. se concentra em deficiências de nitrogênio e potássio em folhas de tomate, nosso projeto utiliza técnicas similares para identificar deficiências de cobre e manganês em folhas de mexerica. Assim, este trabalho oferece uma base metodológica útil, especialmente na escolha de modelos de CNN e na importância de uma abordagem de ensemble para melhorar a precisão no diagnóstico.

Esses resultados indicam que, com o uso apropriado das tecnologias discutidas, nosso projeto NitrusLeaf poderá alcançar resultados satisfatórios. Aproveitando as tecnologias descritas, buscamos oferecer uma funcionalidade avançada ao sistema, permitindo a identificação precisa de deficiências minerais, como as de manganês e cobre, por meio da análise de imagens capturadas pelos usuários.

METODOLOGIA

O desenvolvimento do projeto será conduzido em etapas que seguem a metodologia de desenvolvimento ágil Scrum, permitindo uma adaptação flexível aos requisitos ao longo do processo. Além disso, será utilizada a linguagem UML (Unified Modeling Language) para a elaboração de diagramas de classes, objetos e casos de uso, bem como a aplicação da análise SWOT (Forças, Fraquezas, Oportunidades e Ameaças), a fim de garantir uma compreensão completa da estrutura e do comportamento do sistema.

As principais etapas do projeto são descritas a seguir:

- **1.1 Coleta de Requisitos e Design:** A ferramenta Figma será utilizada para o desenvolvimento de protótipos de baixa e alta fidelidade das interfaces da aplicação. Essa escolha se justifica pela facilidade de uso da plataforma, sua capacidade colaborativa em tempo real e pelos recursos que permitem validar aspectos funcionais e de usabilidade com clareza e agilidade.
- **1.2 Desenvolvimento Front-end:** O código da interface será estruturado com HTML, CSS e React, utilizando o framework Next.js, que oferece recursos avançados como renderização do lado do servidor (SSR), geração de páginas estáticas (SSG) e roteamento dinâmico. Essa abordagem permite maior performance, melhor usabilidade e organização otimizada do projeto. O JavaScript será utilizado para implementar a lógica de interação entre o usuário e a interface, garantindo dinamismo e fluidez. O Node.js será adotado em conjunto para a criação de componentes reutilizáveis e integração com o back-end, aumentando a eficiência e a modularidade do código.
- **1.3 Desenvolvimento Back-end e Banco de Dados:** O DER (Diagrama Entidade-Relacionamento) do banco de dados será modelado utilizando o brModelo, e a implementação será feita com as ferramentas MySQL WorkBench e XAMPP, garantindo uma estrutura robusta e confiável para o armazenamento dos dados. A integração entre o front-end e o back-end será realizada utilizando Node.js, responsável por criar e gerenciar as rotas da aplicação, permitindo a comunicação entre os módulos visuais e os serviços

do sistema. Para os componentes que envolvem visão computacional, será utilizada a linguagem Python, aplicada na análise de imagens por meio de algoritmos de inteligência artificial. No ambiente mobile, será utilizado React Native, devido à sua natureza multiplataforma e à possibilidade de criação de APIs eficientes com bom desempenho em dispositivos móveis.

- **1.4 Treinamento e Avaliação de Algoritmos de IA:** O modelo de IA será baseado em redes neurais convolucionais (CNNs), treinado com imagens rotuladas de folhas de mexerica contendo sintomas de deficiência nutricional. Serão aplicadas técnicas de data augmentation, como variação de brilho, ângulo e contraste, para ampliar a diversidade do conjunto de dados. A eficiência do algoritmo será mensurada por meio de análise de desempenho, utilizando métricas como acurácia, precisão, sensibilidade, F1-score e tempo de execução. A abordagem adotada seguirá o modelo de avaliação empregado por Tran et al. (2019), que compararam arquiteturas como Inception-ResNet v2, Autoencoder CNN e técnicas de Ensemble Averaging para detecção de deficiências nutricionais em folhas de tomate. Da mesma forma, pretende-se validar o modelo proposto com técnicas de validação cruzada e métricas de desempenho estatístico, de forma a garantir confiabilidade e precisão no diagnóstico das deficiências de cobre e manganês.
- **1.5 Testes e Validação:** Após a implementação do sistema, serão conduzidos testes automatizados e manuais para verificar o correto funcionamento de cada componente. Serão utilizadas ferramentas como o Selenium, que permite a automação de testes de interface, com foco na experiência do usuário e na funcionalidade dos elementos visuais da aplicação. Os testes manuais complementarão essa abordagem, possibilitando a verificação de cenários não cobertos pelos testes automatizados.
- **1.6 Publicação e Acompanhamento:** O sistema será inicialmente publicado na plataforma web, com foco no desenvolvimento do front-end e back-end. Em uma etapa futura, funcionalidades presentes na versão web serão adaptadas para o ambiente mobile, permitindo que os agricultores utilizem o aplicativo diretamente no campo para escanear folhas em tempo real e receber diagnósticos imediatos. A arquitetura do sistema será planejada com foco em escalabilidade e manutenção contínua, com atualizações baseadas no feedback dos usuários. Essa abordagem progressiva permitirá a constante evolução do sistema, de forma a atender às reais demandas do setor agrícola e garantir a longevidade e eficácia da solução proposta.

O fluxograma do processo desenvolvido pode ser consultado no Apêndice B.

REFERÊNCIAS

AEGRO. **O que são mapas NDVI e como utilizá-los na fazenda.** Blog Aegro, Porto Alegre, RS. 2020.

Disponível em: <https://blog.aegro.com.br/ndvi/>

.

Acesso em: 29 maio 2024

.

AREGBE, Ikeoluwa; FARNSWORTH, Derek; SIMNITT, Skyler. **Citrus Greening, Hurricanes, and the Decline of the Florida Citrus Industry.** Southern Ag Today. 2024.

Disponível em: <https://southernagtoday.org/2024/01/05/citrus-greening-hurricanes-and-the-decline-of-the-florida-citrus-industry/>

.
Acesso em: 4 maio 2024
.

BRUNA, Jackellyne. **9 micronutrientes das plantas: como e quando utilizá-los**. Blog Aegro, Porto Alegre, RS. 2019.
Disponível em: <https://blog.aegro.com.br/micronutrientes/>
.

Acesso em: 30 maio 2024
.

BUENO, Newton; GASPAROTTO, Luadir. **Sintomas de deficiências nutricionais em citros**. Embrapa Amazônia Ocidental. 1999.
Disponível em: <https://ainfo.cnptia.embrapa.br/digital/bitstream/item/64450/1/CircTec-06-1999.pdf>
.

Acesso em: 19 abr. 2024
.

CHRISTIN, Sylvain; HERVET, Éric; LECOMTE, Nicolas. Applications for deep learning in ecology. **Methods in Ecology and Evolution**, v. 10, p. 1632–1644, 2019. DOI: 10.1111/2041-210X.13256.
Acesso em: 5 maio 2024
.

FUNDECITRUS. **Greening**. Fundecitrus, ciência e sustentabilidade para a citricultura, Araraquara, SP. 2018.
Disponível em: <https://www.fundecitrus.com.br/doencas/greening>
.

Acesso em: 26 abr. 2024
.

GHORAI, Ankit Kumar et al. Image Processing Based Detection of Diseases and Nutrient Deficiencies in Plants. **SATSA Mukhapatra - Annual Technical Issue**, v. 25, p. 1–25, 2021.
Disponível em: <https://www.researchgate.net/publication/349707825>
.

Acesso em: 31 out. 2024
.

MACHADO, Anderson Wolf. **Cobre - tudo o que você precisa saber sobre este adubo**. Agrolink. 2022.
Disponível em: https://www.agrolink.com.br/fertilizantes/nutrientes/cobre---tudo-o-que-voce-precisa-saber-sobre-este-adubo_468470.html
.

Acesso em: 30 maio 2024
.

MUTHUSAMY, Sudhakar; RAMU, Swarna Priya. Computer Vision Based Machine Learning and Deep Learning Approaches for Identification of Nutrient Deficiency in Crops: A Survey. **Nature Environment and Pollution Technology**, v. 22, n. 3, p. 1387–1399, 2023. DOI: 10.46488/NEPT.2023.v22i03.025.

QIN, Zhuwei et al. How convolutional neural networks see the world – A survey of convolutional neural network visualization methods. **Mathematical Foundations of Computing**, v. 1, n. 2, p. 149–180, 2018. DOI: 10.3934/mfc.2018008.

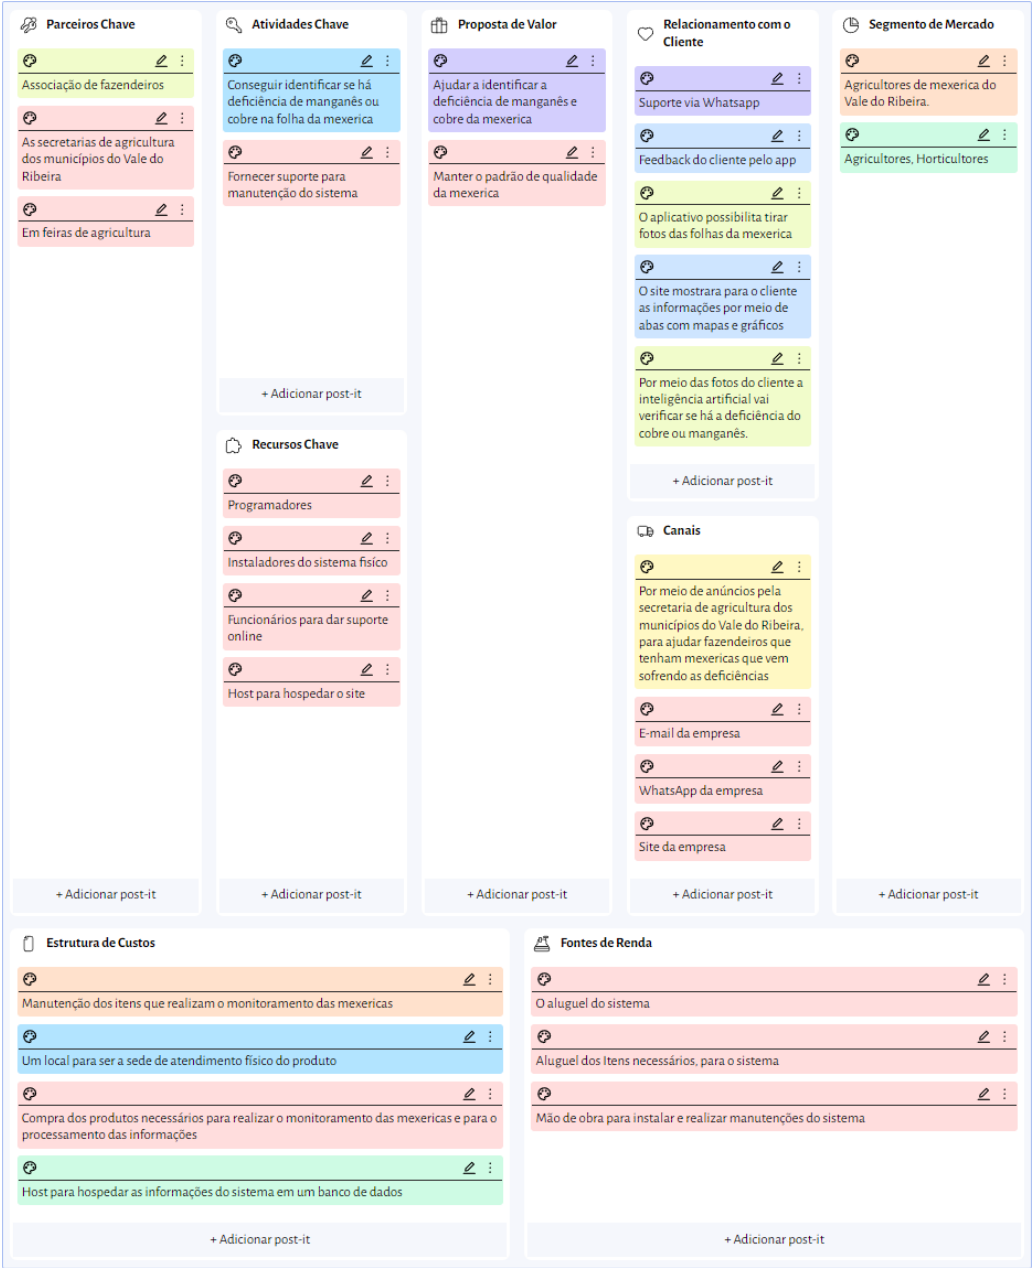
TRAN, Trung-Tin et al. A Comparative Study of Deep CNN in Forecasting and Classifying the Macronutrient Deficiencies on Development of Tomato Plant. **Applied Sciences**, v. 9, n. 8, 2019. DOI: 10.3390/app9081601.

TRINDADE, José Pedro Pereira; VOLK, Leandro Bochi da Silva; ROCHA, Danilo Serra da. **Avaliação do índice normalizado de vegetação no monitoramento de sistema de unidades de manejo**. Bagé: Embrapa Pecuária Sul. 2021.
Disponível em: <https://ainfo.cnptia.embrapa.br/digital/bitstream/item/223511/1/BPD-47-online.pdf>

Acesso em: 29 maio 2024

APÊNDICE A — APÊNDICE A — MODELO DE NEGÓCIOS CANVAS

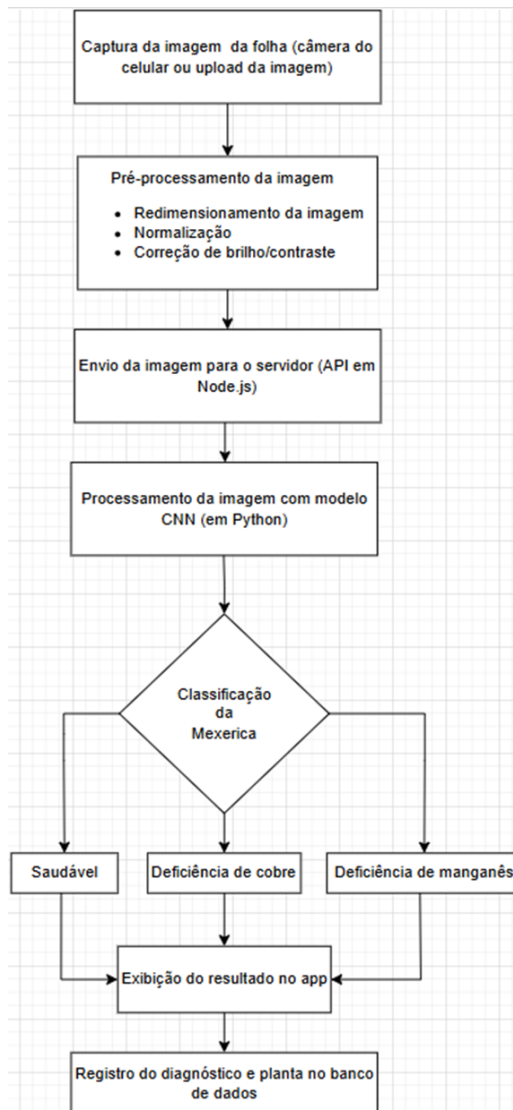
Figura 2 – Figura A.1 - Modelo de negócios Canvas



Fonte: Autoria Própria (2025)

APÊNDICE B — APÊNDICE B — FLUXOGRAMA DO MÉTODO DESENVOLVIDO

Figura 3 – Figura B.1 - Fluxograma do método de diagnóstico automatizado baseado em visão computacional



Fonte: Autoria Própria (2025)