

Classificação de Manganês e Cobre na Folha da Mexerica, Orientado por Redes Neurais

Classification of Manganese and Copper in Tangerine Leaves, Guided by Neural Networks

Fagundes. L { lucas.fagundes3@fatec.sp.gov.br }

Freitas. A { amanda.freitas14@fatec.sp.gov.br }

Freitas. V { valeria.freitas@fatec.sp.gov.br }

RESUMO

Este artigo tem como objetivo alinhar-se ao Objetivo de Desenvolvimento Sustentável (ODS) 2 — Fome Zero e Agricultura Sustentável da Agenda 2030 da Organização das Nações Unidas (ONU), buscando reduzir perdas na produção agrícola e promover práticas mais eficientes e ambientalmente responsáveis. O trabalho apresenta o desenvolvimento inicial do projeto NitrusLeaf, uma solução digital composta por aplicativo móvel e plataforma web, voltada à identificação rápida e precisa de deficiências nutricionais em plantas por meio de *computer vision*. A proposta utiliza técnicas de Inteligência Artificial (IA), com *Convolutional Neural Networks* (CNNs), para analisar imagens de folhas de *Citrus reticulata* (mexerica) e detectar deficiências de cobre e manganês. O treinamento da IA será realizado com um banco de dados em fase de composição, formado a partir de parcerias com produtores locais e instituições agrícolas, prevendo a coleta e rotulagem de centenas de imagens de folhas em diferentes condições nutricionais. Resultados preliminares da pesquisa de campo apontam a recorrência de deficiências de manganês e cobre, além de registros frequentes de *greening* em plantações da região estudada, reforçando a relevância da proposta. Espera-se que, ao final do desenvolvimento, o NitrusLeaf se consolide como uma ferramenta prática e acessível para apoiar diagnósticos nutricionais e contribuir com a sustentabilidade da produção agrícola.

PALAVRAS-CHAVE: Citrus reticulata; Deficiência nutricional; Visão computacional; Manganês; Cobre.

ABSTRACT

This article aims to align with the United Nations (UN) Sustainable Development Goal (SDG) 2 — Zero Hunger and Sustainable Agriculture from the 2030 Agenda, seeking to reduce losses in agricultural production and promote more efficient and environmentally responsible practices. The work presents the initial development of the NitrusLeaf project, a digital solution composed of a mobile application and a web platform designed for the rapid and accurate identification of nutritional deficiencies in plants through computer vision. The proposal employs Artificial Intelligence (AI) techniques, specifically Convolutional Neural Networks (CNNs), to analyze images of Citrus reticulata (mandarin) leaves and detect copper and manganese deficiencies. The AI training will be carried out using a database currently under development, built through partnerships with local producers and agricultural institutions, involving the collection and labeling of hundreds of leaf images under different nutritional conditions. Preliminary results from field research indicate recurrent deficiencies of manganese and copper, as well as frequent occurrences of greening in plantations within the studied region, reinforcing the relevance of the proposal. It is expected that, upon completion, NitrusLeaf will become a practical and accessible tool to support nutritional diagnostics and contribute to the sustainability of agricultural production.

KEYWORDS: Citrus reticulata; Nutritional deficiency; Computer Vision; Manganese; Copper.

INTRODUÇÃO

A escassez de alimentos continua sendo um desafio global, agravado por fatores como pobreza, conflitos e mudanças climáticas. Em resposta, a Organização das Nações Unidas (ONU) instituiu, em 2015, os Objetivos de Desenvolvimento Sustentável (ODS). Entre eles, o ODS 2 — Fome Zero e Agricultura Sustentável — busca assegurar a segurança alimentar por meio do aumento da produtividade agrícola e do uso de tecnologias sustentáveis.

No Brasil, um dos principais entraves à produtividade agrícola está relacionado às deficiências nutricionais nas plantas, especialmente em culturas cítricas como a *Citrus reticulata* (mexerica), que

apresentam elevada sensibilidade a desequilíbrios minerais. Essas deficiências afetam diretamente o desenvolvimento vegetativo e o rendimento da produção, refletindo-se em perdas econômicas para pequenos e médios produtores. Estudos recentes indicam que a concentração de nutrientes em plantas cítricas varia sazonalmente no solo, nas folhas e na seiva do xilema, o que dificulta o diagnóstico preciso do estado nutricional e contribui para manejos inadequados de adubação e correção do solo (Fávero Filho, 2022).

Durante a pesquisa de campo realizada em propriedades rurais produtoras de mexerica, foi observada alta incidência de deficiência de manganês e baixa de cobre, além de numerosos casos de greening (HLB) distribuídos por toda a plantação. Embora o foco deste estudo não seja essa doença, sua menção é relevante, pois os sintomas visuais — como clorose e deformações foliares — podem ser confundidos com deficiências nutricionais, o que reforça a importância de diagnósticos precisos e acessíveis (Fundecitrus, 2021; Aregbe; Farnsworth; Simnitt, 2024).

A carência de manganês manifesta-se por clorose internerval em folhas jovens, enquanto a deficiência de cobre provoca encurtamento dos ramos, folhas pequenas e ocorrência de gomose nos frutos. Essas condições afetam diretamente a produtividade e estão associadas ao pH do solo — sendo o manganês mais escasso em solos ácidos e o cobre em solos mais alcalinos (Bruna, 2019; Machado, 2022).

Durante a última década, técnicas de Inteligência Artificial (IA) e *deep learning* têm sido cada vez mais aplicadas na agricultura de precisão, principalmente no diagnóstico de deficiências nutricionais em plantas. Entre os métodos de aprendizado de máquina, as redes neurais convolucionais (CNNs), uma das principais arquiteturas de *deep learning*, destacam-se por sua capacidade de extrair automaticamente características visuais complexas de imagens, sem a necessidade de pré-processamento extensivo ou seleção manual de atributos. Diferentemente de algoritmos clássicos, como SVMs, árvores de decisão ou k-NN, que dependem fortemente de variáveis pré-definidas e da engenharia de características, as CNNs conseguem aprender representações hierárquicas diretamente a partir das imagens das folhas, capturando padrões sutis de clorose, deformações ou manchas associadas a deficiências nutricionais (Qin et al., 2018; Christin; Hervet; Lecomte, 2019).

Ao integrar tais tecnologias ao contexto agrícola brasileiro, o projeto busca contribuir com os objetivos do ODS 2 — Fome Zero e Agricultura Sustentável — promovendo práticas mais sustentáveis, reduzindo perdas na produção e fortalecendo a segurança alimentar por meio da inovação tecnológica.

OBJETIVO

A citricultura enfrenta desafios constantes relacionados a doenças e deficiências nutricionais que comprometem o desenvolvimento saudável das plantas e reduzem a produtividade. Embora essas condições possam ser identificadas visualmente por alterações nas folhas, cascas e frutos, o diagnóstico tradicional — baseado em análises químicas — é demorado, exige coleta física e depende de infraestrutura laboratorial especializada. Nesse cenário, o uso da IA aplicada à visão computacional apresenta-se como uma alternativa acessível e eficiente, permitindo diagnósticos rápidos e automáticos diretamente no campo.

Diante desse contexto, o presente projeto tem como objetivo geral desenvolver um sistema inteligente, baseado em visão computacional, capaz de identificar deficiências de manganês e cobre em folhas de mexerica por meio da análise de imagens capturadas com dispositivos móveis. A proposta busca oferecer maior agilidade e precisão no diagnóstico nutricional, contribuindo para a sustentabilidade da produção e a redução de perdas causadas por deficiências minerais.

Objetivos Específicos:

1. Construir um banco de dados com imagens rotuladas de folhas de mexerica apresentando

diferentes níveis de deficiência de manganês e cobre, de modo a compor uma base de dados representativa para o treinamento da IA.

2. Treinar e validar uma CNN utilizando técnicas de aumento de dados, validação cruzada e ajuste de hiperparâmetros, com o objetivo de otimizar a acurácia do modelo.
3. Implementar um protótipo funcional que permita ao agricultor obter diagnósticos automatizados, por meio da captura de imagens via smartphone, com base na análise da IA.

Resultados Esperados:

Com o desenvolvimento do sistema, espera-se disponibilizar uma ferramenta prática e acessível para pequenos e médios produtores, reduzindo o tempo e o custo do diagnóstico nutricional. A solução visa auxiliar na detecção precoce de deficiências minerais, promover o uso racional de insumos e fortalecer práticas agrícolas mais sustentáveis e eficientes.

Trabalhos Futuros:

Futuras etapas do projeto poderão expandir a aplicação do sistema inteligente para além do diagnóstico em folhas de mexerica. Entre as possibilidades, destacam-se o uso de drones para captura de imagens em grande escala, a geração de mapas de calor indicando áreas com deficiências nutricionais na plantação e a adaptação do modelo para outras culturas cítricas ou frutíferas, ampliando o alcance e a utilidade da ferramenta para diferentes contextos agrícolas.

ESTADO DA ARTE

A pesquisa científica tem se voltado para o desenvolvimento de tecnologias que auxiliem o diagnóstico rápido e preciso de deficiências nutricionais em plantas, especialmente em culturas de relevância econômica, como a mexerica. A identificação visual dessas deficiências é um desafio recorrente, e soluções baseadas em visão computacional e *deep learning* têm se mostrado promissoras por permitirem análises automatizadas e de baixo custo. A seguir, são apresentados três trabalhos científicos que exploram essas abordagens e servem como referência para o desenvolvimento do projeto NitrusLeaf.

No trabalho de Muthusamy e Ramu (2023), foi proposto um sistema de monitoramento agrícola baseado em visão computacional, *machine learning* e *deep learning*. O estudo aplicou essas técnicas em diferentes culturas agrícolas, utilizando imagens de satélite, sensoriamento remoto, *Internet of Things* (IoT) e Veículos Aéreos Não Tripulados (VANTs) para capturar dados visuais em tempo real e identificar deficiências nutricionais. O método integrou sensores e câmeras de alta resolução que coletaram imagens sob variadas condições ambientais, processadas por algoritmos de IA capazes de identificar padrões visuais como cor, textura e bordas. Os resultados mostraram diagnósticos rápidos e não invasivos, otimizando o manejo agrícola e o uso de insumos. Como limitação, os autores apontaram o alto custo dos equipamentos e a dificuldade de aplicação em pequenas propriedades. Esse estudo fornece base teórica relevante para o NitrusLeaf, especialmente quanto ao uso de algoritmos de visão computacional, embora o projeto atual priorize a acessibilidade e o uso direto em campo com dispositivos móveis.

Ghorai et al. (2021) desenvolveram um *pipeline* para detecção automatizada de doenças e deficiências nutricionais em plantas, utilizando processamento digital de imagens. A metodologia foi estruturada em seis etapas: aquisição da imagem, pré-processamento, segmentação, extração de características, classificação e diagnóstico. As imagens foram capturadas por câmeras acopladas a drones e dispositivos móveis e, posteriormente, padronizadas com técnicas de correção de ruído e ajuste de contraste. A análise das características visuais envolveu cor, textura e forma, destacando o uso da Matriz de Coocorrência de Níveis de Cinza (GLCM) e histogramas de cor. A classificação foi realizada

com redes neurais convolucionais (CNNs) e Máquinas de Vetores de Suporte (SVMs), resultando em acurácia superior a 90%. Apesar do bom desempenho, os autores destacaram limitações quanto à generalização dos modelos em diferentes espécies, devido à necessidade de bases de dados mais diversificadas. A abordagem é relevante para o NitrusLeaf por oferecer uma estrutura metodológica aplicável à análise de folhas de mexerica, permitindo a detecção precisa das deficiências de cobre e manganês.

Tran et al. (2019) aplicaram redes neurais convolucionais para detectar deficiências de cálcio, nitrogênio e potássio em tomateiros, utilizando modelos Inception-ResNet v2, Autoencoder e uma combinação híbrida por *ensemble averaging*. O conjunto de dados foi composto por 571 imagens coletadas em estufas, sendo 80% destinadas ao treinamento e 20% à validação. Foram aplicadas técnicas de pré-processamento e *data augmentation*, como variação de ângulo, brilho e contraste, para aprimorar a generalização dos modelos. Os resultados mostraram acurácia de 87,27% para o Inception-ResNet v2, 79,09% para o Autoencoder e 91% para o *ensemble*. O estudo demonstrou que abordagens híbridas aumentam a precisão dos diagnósticos, embora exijam alto custo computacional e recursos de hardware avançados. Para o NitrusLeaf, os resultados de Tran et al. (2019) reforçam a importância de arquiteturas otimizadas que equilibrem desempenho e eficiência, considerando o uso em dispositivos móveis e ambientes agrícolas.

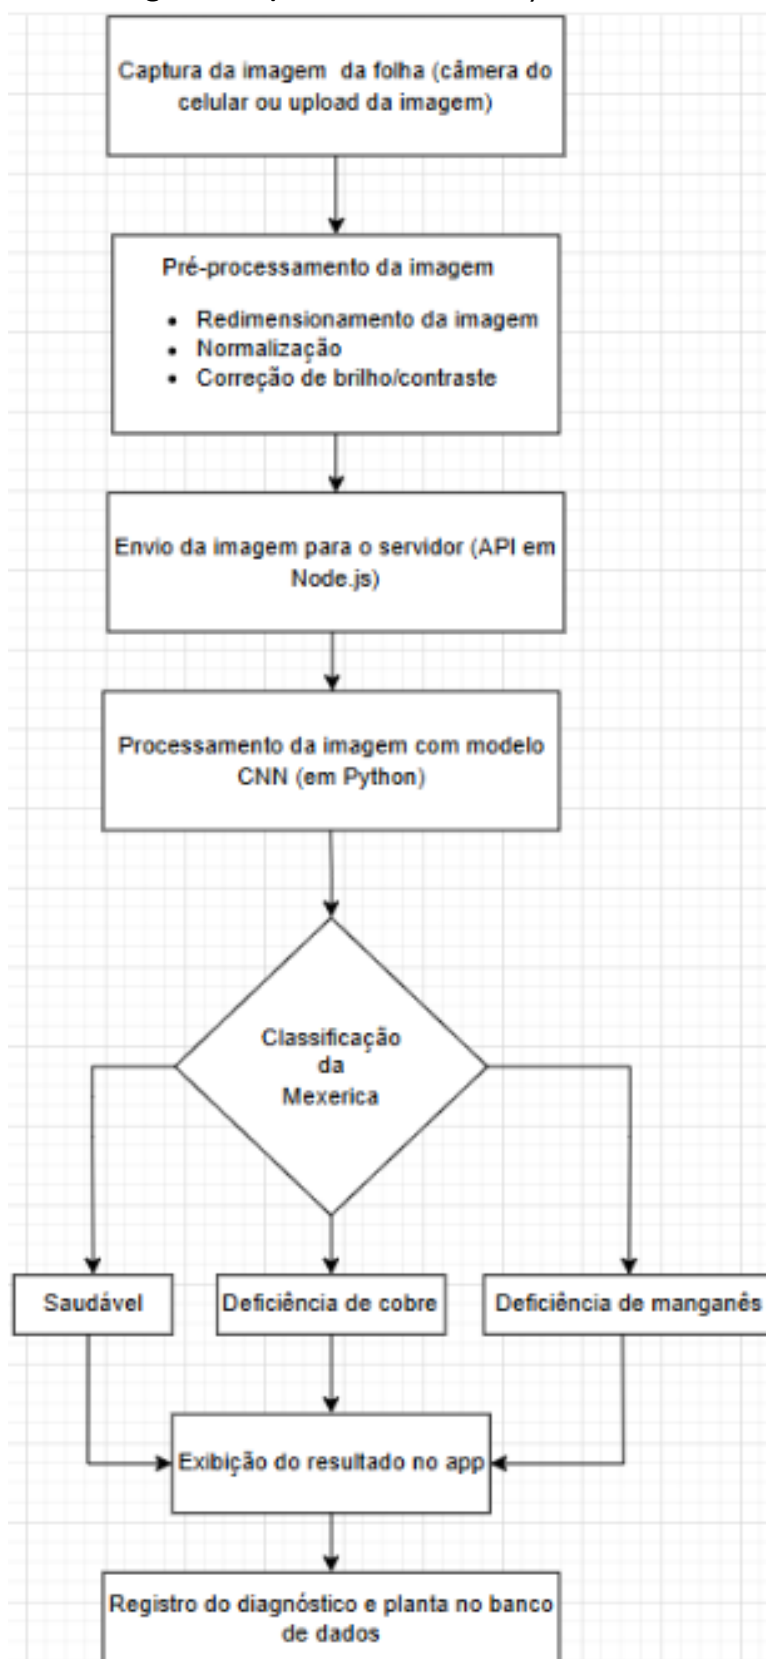
A análise comparativa dos três trabalhos evidencia abordagens complementares e contribuições significativas. Muthusamy e Ramu (2023) propõem uma aplicação em larga escala com integração de tecnologias inteligentes; Ghorai et al. (2021) apresentam uma metodologia acessível e bem estruturada baseada em etapas de processamento de imagem; e Tran et al. (2019) demonstram o potencial das redes híbridas para diagnósticos de alta precisão. O NitrusLeaf combina elementos dessas pesquisas, adaptando-os à realidade da mexerica, com foco na detecção de deficiências de cobre e manganês por meio de IA aplicada a dispositivos móveis. A proposta busca unir precisão técnica, baixo custo operacional e aplicabilidade prática, atendendo especialmente às necessidades de pequenos e médios produtores rurais.

METODOLOGIA

O desenvolvimento do projeto NitrusLeaf foi estruturado em etapas organizadas de forma sequencial e iterativa, com base em princípios de desenvolvimento ágil, visando flexibilidade e adaptação ao longo do processo. O método adotado busca garantir a integração eficiente entre as etapas de análise, implementação e validação dos resultados, assegurando a qualidade e a aplicabilidade da solução desenvolvida.

A Figura 1 apresenta o fluxograma geral do processo metodológico, descrevendo a sequência lógica das atividades realizadas, desde a captura das imagens até o registro final dos diagnósticos no sistema.

Figura 1 – Fluxograma do processo de classificação das folhas de mexerica



Fonte: Fonte: autoria própria (2025)

A seguir, descrevem-se detalhadamente as etapas que compõem o processo metodológico representado no fluxograma:

1. **Coleta de Requisitos e Planejamento do Sistema**

Nesta etapa inicial, foram levantados os requisitos funcionais e não funcionais do sistema, definindo-se as principais funcionalidades e fluxos de interação. Para o planejamento da interface e prototipagem, utilizou-se o Figma, devido à sua facilidade de colaboração e à capacidade de criar protótipos interativos de baixa e alta fidelidade. Essa fase também incluiu a elaboração de diagramas UML para a representação da estrutura do sistema e análise SWOT para identificar forças, fraquezas, oportunidades e ameaças, garantindo uma visão ampla do projeto presente no apêndice A.

2. **Captura e Pré-processamento das Imagens**

O processo tem início com a captura de imagens de folhas de mexerica por meio da câmera do celular ou upload de imagens previamente armazenadas. As imagens passam por etapas de pré-processamento, incluindo redimensionamento, normalização e correção de brilho e contraste. Essas operações garantem a padronização dos dados visuais, fundamentais para o bom desempenho da CNN durante a classificação.

3. **Envio e Processamento das Imagens**

Após o pré-processamento, as imagens são enviadas para o servidor por meio de uma API desenvolvida em Node.js. No servidor, o modelo de IA implementado em Python realiza o processamento utilizando redes neurais convolucionais (CNNs) treinadas previamente com imagens rotuladas de folhas saudáveis e com deficiências de cobre e manganês. Essa etapa representa o núcleo analítico do sistema, onde ocorre a classificação automática das imagens.

4. **Classificação e Exibição dos Resultados**

O modelo realiza a classificação das folhas em três categorias: saudável, deficiência de cobre ou deficiência de manganês. O resultado é exibido no aplicativo em tempo real, fornecendo ao usuário um diagnóstico rápido e acessível. Essa abordagem visa permitir a identificação imediata de deficiências no campo, reduzindo o tempo entre o diagnóstico e a tomada de decisão pelo agricultor.

5. **Registro e Armazenamento dos Diagnósticos**

Os diagnósticos gerados são armazenados no banco de dados, associados ao registro da planta e ao talhão correspondente. Essa funcionalidade possibilita o acompanhamento histórico do estado nutricional das plantas, facilitando análises posteriores e o monitoramento contínuo das condições do cultivo.

6. **Treinamento e Avaliação do Modelo**

O treinamento do modelo de IA foi realizado a partir de um conjunto de imagens rotuladas, aplicando técnicas de *data augmentation* para aumentar a diversidade visual do conjunto. Foram utilizadas métricas de desempenho como acurácia, precisão e F1-score para validar o modelo. A metodologia de avaliação segue princípios semelhantes aos empregados por Tran et al. (2019), que demonstraram a importância da validação cruzada e da comparação de arquiteturas para garantir resultados consistentes e confiáveis.

7. **Ferramentas Utilizadas**

Para a implementação do sistema, foram empregadas diferentes ferramentas tecnológicas. O front-end foi desenvolvido com React e Next.js, oferecendo desempenho otimizado e boa organização estrutural. O back-end foi construído em Node.js, responsável pela integração com o banco de dados e a comunicação com o modelo de IA. O armazenamento de dados

foi realizado com MySQL, escolhido pela robustez e ampla compatibilidade. O módulo de visão computacional foi desenvolvido em Python, pela facilidade de integração com bibliotecas voltadas à IA, como TensorFlow e Keras.

8. **Treinamento do Modelo e Controle de Qualidade das Imagens**

Prevê-se a utilização de um conjunto de aproximadamente 1.500 imagens de folhas de mexerica, abrangendo amostras saudáveis e com deficiências de cobre e manganês. As imagens serão divididas em conjuntos de treinamento 70

O modelo de aprendizado profundo será baseado em uma arquitetura pré-treinada, como a VGG16 ou ResNet50, aproveitando técnicas de *transfer learning* para otimizar o desempenho com um conjunto de dados reduzido.

Será implementado um controle rigoroso de qualidade das imagens, envolvendo filtros automáticos para detecção de ruído, variações excessivas de iluminação e ângulos inadequados de captura. Espera-se, assim, assegurar a consistência visual do dataset e aprimorar a acurácia da classificação realizada pela rede neural convolucional.

REFERÊNCIAS

AREGBE, Ikeoluwa; FARNSWORTH, Derek; SIMNITT, Skyler. **Citrus Greening, Hurricanes, and the Decline of the Florida Citrus Industry**. Southern Ag Today. 2024.

Disponível em: <https://southernagtoday.org/2024/01/05/citrus-greening-hurricanes-and-the-decline-of-the-florida-citrus-industry/>

Acesso em: 24 out. 2025

BRUNA, Jackellyne. **9 micronutrientes das plantas: como e quando utilizá-los**. Blog Aegro, Porto Alegre, RS. 2019.

Disponível em: <https://blog.aegro.com.br/micronutrientes/>

Acesso em: 24 out. 2025

CHRISTIN, Sylvain; HERVET, Éric; LECOMTE, Nicolas. Applications for deep learning in ecology. **Methods in Ecology and Evolution**, v. 10, p. 1632–1644, 2019. DOI:

10.1111/2041-210X.13256.

Acesso em: 26 out. 2025

FÁVERO FILHO, Pedro Luiz. **Sazonalidade da concentração de nutrientes no solo, nas folhas e na seiva do xilema do citros**. Dissertação (Mestrado em Agronomia) – Escola Superior de Agricultura “Luiz de Queiroz”, Universidade de São Paulo, Piracicaba. 2022.

Disponível em:

<https://www.teses.usp.br/teses/disponiveis/11/11136/tde-10082022-155410/>

Acesso em: 26 out. 2025

FUNDECITRUS. **Greening**. Fundecitrus, ciência e sustentabilidade para a citricultura, Araraquara, SP. 2021.

Disponível em:

<https://www.fundecitrus.com.br/pragas-e-doencas/greening-e-psilideo/>

Acesso em: 25 out. 2025

GHORAI, Ankit Kumar et al. Image Processing Based Detection of Diseases and Nutrient Deficiencies in Plants. **SATSA Mukhapatra - Annual Technical Issue**, v. 25, p. 1–25, 2021.

Disponível em: <https://www.researchgate.net/publication/349707825>

Acesso em: 26 out. 2025

MACHADO, Anderson Wolf. **Cobre - tudo o que você precisa saber sobre este adubo**.

Agrolink. 2022.

Disponível em: https://www.agrolink.com.br/fertilizantes/nutrientes/cobre---tudo-o-que-voce-precisa-saber-sobre-este-adubo_468470.html

Acesso em: 24 out. 2025

MUTHUSAMY, Sudhakar; RAMU, Swarna Priya. Computer Vision Based Machine Learning and Deep Learning Approaches for Identification of Nutrient Deficiency in Crops: A Survey. **Nature Environment and Pollution Technology**, v. 22, n. 3, p. 1387–1399, 2023. DOI:

10.46488/NEPT.2023.v22i03.025.

QIN, Zhuwei et al. How convolutional neural networks see the world – A survey of convolutional neural network visualization methods. **Mathematical Foundations of Computing**, v. 1, n. 2, p. 149–180, 2018. DOI: 10.3934/mfc.2018008.

TRAN, Trung-Tin et al. A Comparative Study of Deep CNN in Forecasting and Classifying the Macronutrient Deficiencies on Development of Tomato Plant. **Applied Sciences**, v. 9, n. 8, 2019. DOI: 10.3390/app9081601.

APÊNDICE A — APÊNDICE A — ANÁLISE SWOT

Figura 2 – Figura A.1 - Análise SWOT do projeto NitrusLeaf

Pontos Fortes <ul style="list-style-type: none">• É alinhado com iniciativas sustentáveis.• Melhora a eficiência e rapidez no diagnóstico de doenças.• Reduz o risco de pés de mexerica ainda saudáveis.• Reduz o desperdício de alimentos saudáveis.• É alinhado com os objetivos da ODS.	Fraquezas <ul style="list-style-type: none">• Poucos estudos na área envolvendo plantas cítricas.• O treinamento do modelo da IA depende de um grande banco de dados.• O diagnóstico depende da qualidade da imagem.• Dificuldade ao acesso à internet por parte dos produtores.
Oportunidades <ul style="list-style-type: none">• Expandir para outras deficiências como: zinco, ferro etc.• Parcerias com empresas, cooperativas e universidades para divulgar o produto.• Crescente demanda por agricultura de precisão.	Ameaças <ul style="list-style-type: none">• Resistência por parte dos produtores tradicionais.• Concorrência com outras soluções como drones por exemplo.

Fonte: Autoria Própria (2025)